

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



NGUYỄN HỮU TUẤN

NHẬN DIỆN NGÔN NGỮ KÝ HIỆU ĐỒ ÁN NGÀNH

ĐỒ ÁN NGÀNH
NGÀNH KHOA HỌC MÁY TÍNH

TP. Hồ Chí Minh, 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



NGUYỄN HỮU TUẤN - 2251012151

NHẬN DIỆN NGÔN NGỮ KÝ HIỆU ĐỒ ÁN NGÀNH

ĐỒ ÁN NGÀNH
NGÀNH KHOA HỌC MÁY TÍNH

Giảng viên hướng dẫn:
TS. LÊ VIẾT TUẤN

TP. Hồ Chí Minh, 2025

Lời cảm ơn

Trước tiên, em xin gửi lời cảm ơn chân thành đến quý thầy cô khoa Công nghệ thông tin trường Đại học Mở Thành phố Hồ Chí Minh, những người đã tận tình giảng dạy, truyền đạt kiến thức và tạo điều kiện thuận lợi cho em trong suốt quá trình học tập tại trường.

Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc đến thầy Lê Viết Tuấn - người đã trực tiếp hướng dẫn, định hướng và hỗ trợ em trong suốt quá trình thực hiện môn học Đồ án ngành. Nhờ sự tận tình chỉ bảo, những góp ý quý báu của thầy, em đã có thể hoàn thành tốt đề tài nghiên cứu của mình.

Em cũng xin gửi lời cảm ơn đến các anh/chị, bạn bè và gia đình đã luôn đồng hành, động viên, hỗ trợ em cả về tinh thần và kiến thức trong suốt quá trình học tập và hoàn thành môn học.

Mặc dù đã cố gắng hết sức, nhưng đồ án này khó tránh khỏi những thiếu sót. Em rất mong nhận được sự thông cảm và góp ý từ quý thầy cô để em có thể hoàn thiện hơn trong các nghiên cứu sau này.

Em xin chân thành cảm ơn!

Nguyễn Hữu Tuấn

Ý kiến cho phép bảo vệ Khóa luận tốt nghiệp của Giảng viên hướng dẫn

Giảng viên hướng dẫn: TS. Lê Viết Tuấn

Sinh viên thực hiện: Nguyễn Hữu Tuấn

Tóm tắt

Ngôn ngữ ký hiệu là phương tiện giao tiếp của người khiếm thị, khiếm ngôn. Giống với các loại ngôn ngữ bình thường khác, ngôn ngữ ký hiệu cũng có cấu trúc, hệ thống ngữ pháp, từ vựng đầy đủ. Thêm nữa là sự đa dạng về ngôn ngữ ký hiệu, mỗi quốc gia có thể có bộ ngôn ngữ ký hiệu riêng, thậm chí là mỗi vùng, khu vực trong một đất nước có thể biểu diễn các ký hiệu khác nhau.

Nhờ ngôn ngữ ký hiệu đã góp phần tạo ra sự đa dạng trong môi trường giao tiếp, nhưng nó cũng là rào cản lớn trong giao tiếp. Không phải ai cũng có thể hiểu được ngôn ngữ ký hiệu. Trong giao tiếp giữa người dùng ngôn ngữ ký hiệu và người không hiểu ngôn ngữ ký hiệu là một bức tường lớn cản trở việc giao tiếp...

Trong thời đại phát triển mạnh mẽ của khoa học kỹ thuật, cụ thể hơn là sự phát triển của Trí tuệ nhân tạo (AI), thị giác máy tính (Computer Vision) đã mở ra những hướng nghiên cứu đầy tiềm năng ứng dụng vào thực tiễn. Đến với bài báo cáo môn Đồ án ngành này, với đề tài nhận diện ngôn ngữ ký hiệu, tôi đã tìm hiểu, nghiên cứu các phương pháp, và thực nghiệm đưa ra một mô hình nhận diện ngôn ngữ ký hiệu dựa trên bộ khung xương. Đề tài của tôi được áp dụng các kỹ thuật như mã hóa, giải mã, hiệu chỉnh bản tay giúp hình ảnh bàn tay trở nên chân thực hơn, kỹ thuật SMOTE để tăng cường dữ liệu... Đồng thời, có sự kết hợp của các cơ chế như cơ chế tách biệt các bộ phận cơ thể giúp tránh các đặc trưng có thể học độc lập nhau, tránh sự thiếu sót của một bộ phận mà làm ảnh hưởng đến các bộ phận khác; nữa là cơ chế phân loại nội bộ giúp mô hình giảm đáng kể hiệu suất tính toán; nổi bật hơn là cơ chế giao tiếp giữa các bộ phận quan trọng góp phần nắm bắt ngữ cảnh, trao đổi thông tin với bộ phận khác.

Mô hình được tinh chế và được đánh giá trên hai bộ dữ liệu của WLASL100 và LSA64. Hai bộ dữ liệu này là dữ liệu phục vụ cho nhận diện ngôn ngữ ký hiệu ở mức độ từ vựng. Bộ dữ liệu WLASL100 là một tập con của WLASL (Word-Level American Sign Language). WLASL100 là ngôn ngữ ký hiệu của người Mỹ, với 2038 video biểu diễn 100 ký hiệu ở cấp độ từ vựng. Đối với LSA64 đây là bộ dữ liệu biểu diễn ngôn ngữ Argentina, gồm 64 ký hiệu. Hai bộ dữ liệu này là 2 bộ dữ liệu chuẩn, nổi tiến thường xuyên được sử dụng để xây dựng, đánh giá các mô hình ngôn ngữ ký hiệu ở mức độ từ vựng.

Với những kỹ thuật và cơ chế quan trọng, mô hình mà tôi nghiên cứu đã đạt được một kết quả khả quan góp phần tạo động lực cho những nghiên cứu về nhận diện ngôn ngữ ký hiệu sau này.

Mục lục

Lời cảm ơn	ii
Ý kiến Giảng viên hướng dẫn	iii
Tóm tắt	iv
Mục lục	v
Danh sách bảng	vi
1 Giới thiệu	1
1.1 Tổng quan	1
1.2 Lý do chọn đề tài	2
1.3 Mục tiêu nghiên cứu	2
1.4 Đối tượng nghiên cứu	2
1.5 Phạm vi nghiên cứu	3
2 Các công trình liên quan	4
2.1 Phương pháp dựa trên video/hình ảnh (RGB-based)	4
2.2 Phương pháp dựa trên bộ xương (Pose-based)	4
2.3 Phương pháp lai	5
2.4 Nghiên cứu liên quan đến bộ dữ liệu WLASL100	5
2.5 Nghiên cứu liên quan đến bộ dữ liệu LSA64	5
3 Phương pháp	6
3.1 Tiền xử lý	6
3.2 Chỉnh khớp tay theo động lực học	8
3.3 Cơ chế tách biệt các bộ phận cơ thể	9
3.3.1 Mã hóa vị trí theo khung hình	11
3.3.2 Cơ chế ProbSparse Attention	11
3.3.3 Tách biệt các bộ phận	12
3.4 Giao tiếp giữa các bộ phận	13
3.5 Cơ chế suy luận thích ứng đầu vào	14
4 Thực nghiệm	15
4.1 Chi tiết thực nghiệm	15
4.1.1 Tập dữ liệu	15
4.1.2 Cấu hình thiết bị thực nghiệm	15
4.1.3 Các tham số huấn luyện	15

4.2	Phân tích hiệu chỉnh động lực học	16
4.3	Hiệu quả của số lượng lớp <i>Communicating - Encoder - Decoder</i>	16
4.4	Đánh giá hiệu quả của cơ chế suy luận thích ứng đầu vào	17
4.5	So sánh	19
5	Kết luận	21
5.1	Kết luận	21
5.2	Hướng phát triển	21
	Tài liệu tham khảo	24

Danh sách bảng

2.1	Các nghiên cứu tiêu biểu trên bộ dữ liệu WLASL100	5
2.2	Các nghiên cứu tiêu biểu trên bộ dữ liệu LSA64	5
3.1	Các ràng buộc về dạng - khớp và duỗi - gấp của tay	9
4.1	Hiệu quả của số lượng lớp trên tập dữ liệu WLASL100	16
4.2	Khảo sát giá trị <i>patience</i>	17
4.3	Khảo sát giá trị <i>patience</i> riêng cho từng khối trên WLASL100	18
4.4	Bảng thống kê số mẫu thử nghiệm thoát sớm của <i>Encoder</i>	18
4.5	Hiệu quả của suy luận thích ứng theo đầu vào	18
4.6	Sự đóng góp của từng luồng bộ phận vào quyết định dừng sớm	19
4.7	So sánh các công trình trên tập dữ liệu WLASL100	19
4.8	So sánh các công trình trên tập dữ liệu LSA64	20

Chương 1

Giới thiệu

1.1 Tổng quan

Ngôn ngữ ký hiệu là phương tiện giao tiếp chính của cộng đồng người khiếm thính, người khiếm ngôn trên toàn thế giới. Theo thống kê của Tổ chức Y tế Thế giới (WHO), hơn 5% dân số thế giới - tương đương 430 triệu người bị suy giảm thính lực, trong đó có hơn 34 triệu trẻ em. Tại Việt Nam, số lượng người khiếm thính ước tính khoảng 2,5 triệu người. Điều này cho thấy vấn đề giao tiếp giữa những người khiếm thính, khiếm ngôn và cộng đồng là rất cấp thiết.

Ngôn ngữ ký hiệu không chỉ đơn thuần là những cử chỉ của tay, mà nó là một hệ thống ngôn ngữ hoàn chỉnh có ngữ pháp, từ vựng, cấu trúc câu riêng biệt... Thậm chí mỗi quốc gia có thể có ngôn ngữ ký hiệu riêng.

Để giải quyết vấn đề cấp thiết này, việc ứng dụng trí tuệ nhân tạo (AI) và học máy (Machine Learning) vào ứng dụng đời sống, cụ thể ở đây là ứng dụng vào nhận diện ngôn ngữ ký hiệu trở thành một hướng nghiên cứu cực kỳ tiềm năng. Thêm vào đó là các công nghệ xử lý ảnh số, thị giác máy tính (Computer Vision), và học sâu (Deep Learning) đã cho thấy được tiềm năng, một kết quả khả quan trong việc nhận diện và phiên dịch các ký hiệu tay.

Trong thời đại công nghệ thông tin phát triển mạnh mẽ, nhận diện ngôn ngữ ký hiệu là đề tài đang được thu hút nhiều nhà nghiên cứu. Tuy nhiên các phương pháp dựa trên bộ khung xương còn bộc lộ nhiều hạn chế:

- (1) Tính tổng quát hóa của các mô hình kém do dữ liệu thiếu thực tế: Các mô hình được huấn luyện trên bộ dữ liệu lý tưởng, cái mà mọi bộ phận của người biểu diễn ký hiệu được trích xuất một cách trọn vẹn. Tuy nhiên, trong thực tế, khi biểu diễn một ký hiệu thì thường bị che lấp đi - có thể tay bị che khuất bởi chính tay còn lại, hay các cử chỉ quá nhanh không nắm được các nốt tay... Làm cho mô hình kém hiệu quả trong môi trường thực tế.
- (2) Đánh giá các từ, ký hiệu đều có độ phức tạp bằng nhau. Có những ký hiệu đơn giản, chỉ cần 1 tay, nhưng có những ký hiệu cực kỳ phức tạp, cần 2 tay và chuyển động nhanh. Việc đánh giá các ký hiệu có cùng độ phức tạp khiến cho mô hình suy nghĩ quá mức, mô hình trở nên phức tạp, nặng chi phí tính toán, khó áp dụng thực tiễn.
- (3) Vấn đề về dữ liệu khung xương thiếu tính chính xác. Dữ liệu khung xương đầu vào thường được trích xuất bởi các mô hình ước tính tư thế, và các công cụ này không phải lúc nào cũng hoàn hảo. Các mô hình này có thể tạo ra các điểm khớp sai ví dụ như khớp ngón tay bị gấp ngược, làm ảnh hưởng đến độ tin cậy của dữ liệu huấn luyện và suy luận của mô hình.

Để khắc phục với các hạn chế cốt lõi trên, đề án này đề xuất các giải pháp tương ứng như sau:

- Thứ nhất, thay vì xử lý các điểm khớp của bộ xương đi vào 1 luồng duy nhất để học và phân loại ký hiệu, tôi chia các bộ phận thành 3 luồng riêng biệt (tay trái, tay phải, phần thân). Chính

vì vậy, dù nếu 1 bộ phận nào đó không tham gia vào biểu diễn ký hiệu hay bị nhận dạng thiếu thì cũng sẽ không ảnh hưởng đến bộ phận khác.

- (2) Thứ hai, tôi sẽ dựa vào tư thế tay theo động học để có thể điều chỉnh những điểm khớp bị sai lệch. Bởi bàn tay là bộ phận vô cùng quan trọng trong biểu diễn ngôn ngữ ký hiệu. Việc các mô hình nhận diện một điểm khớp nào đó của bàn tay bị sai lệch so quá mức là không thực tế.
- (3) Thứ ba, dùng suy luận thích ứng với dữ liệu đầu vào. Sau mỗi lớp, một bộ phân loại nội bộ sẽ đưa ra dự đoán tạm thời. Hệ thống sẽ kiểm tra xem dự đoán này có thay đổi so với lớp trước đó không. Nếu không có sự thay đổi qua N lần thì mô hình sẽ dừng quá trình suy luận và trả về kết quả đó.

Với cơ chế này, đối với các ký hiệu dễ mô hình không cần chạy hết tất cả các lớp để đưa ra câu trả lời, mà chỉ cần qua vài lớp. Đối với các ký hiệu phức tạp mô hình sẽ chạy qua các lớp để có kết quả dự đoán chính xác hơn. Điều này giúp giảm chi phí tính toán, thời gian xử lý, đặc biệt đối với các ký hiệu đơn giản.

- (4) Cuối cùng, cơ chế giao tiếp giữa các bộ phận cốt lõi. Việc tách riêng các bộ phận ra từng luồng riêng biệt nhau làm cho các bộ phận không thể liên hệ, học hỏi lẫn nhau, chính vì thế cơ chế giao tiếp giúp cho bộ phận có thể hiểu được ngữ cảnh hiện tại của bộ phận còn lại làm giàu thông tin của đặc trưng.

1.2 Lý do chọn đề tài

Nhận dạng ngôn ngữ ký hiệu là một trong những hướng nghiên cứu có tính ứng dụng thực tiễn cao và mang ý nghĩa xã hội sâu sắc. Mặc dù là phương tiện giao tiếp chính của cộng đồng người khiếm thính, ngôn ngữ ký hiệu lại là một rào cản đối với phần lớn xã hội. Việc phát triển một hệ thống có khả năng tự động phiên dịch ngôn ngữ ký hiệu sẽ đóng vai trò cầu nối, xóa bỏ rào cản giao tiếp và thúc đẩy sự hòa nhập, bình đẳng.

1.3 Mục tiêu nghiên cứu

Trong khuôn khổ của đề án ngành, em đã đặt ra các mục tiêu chính:

- Nghiên cứu về cơ sở lý thuyết: Tìm hiểu tổng quan về ngôn ngữ ký hiệu, phân tích các phương pháp và kiến trúc của mô hình liên quan tiêu biểu được ứng dụng cho bài toán nhận dạng hành động.
- Tìm hiểu và khắc phục các thách thức của các mô hình hiện tại.
- Cải tiến và nâng cao hiệu suất mô hình nhận diện ngôn ngữ ký hiệu.

1.4 Đối tượng nghiên cứu

- Tìm hiểu, nghiên cứu các phương pháp trích xuất đặc trưng trong bộ dữ liệu Word-Level American Sign Language [14], và dùng một tập con của bộ dữ liệu WLASL100 để nghiên cứu. Thêm vào đó,

để khẳng định tính đúng đắn của mô hình, bộ dữ liệu LSA64 [19] - bộ dữ liệu ngôn ngữ ký hiệu của Argentina được sử dụng để kiểm tra, chứng minh tính đúng đắn.

- Các mô hình học sâu cho các bài toán phân loại bài toán chuỗi thời gian cụ thể là mô hình nhận diện ngôn ngữ ký hiệu Siformer [18].

1.5 Phạm vi nghiên cứu

- Trong đề án này tập trung vào bài toán phân loại các từ, không xét đến ngôn ngữ ký hiệu liên tục trong câu.

- Mô hình được phát triển và đánh giá trên bộ dữ liệu Word-Level American Sign Language 100 (WLASL100) và LSA64.

Chương 2

Các công trình liên quan

Lĩnh vực Nhận dạng ngôn ngữ ký hiệu đã trải qua một quá trình phát triển dài, từ các phương pháp truyền thống dựa trên các đặc trưng thủ công cho đến các kiến trúc học sâu hiện đại. Nhìn chung, các công trình hiện có thể được phân loại thành hai hướng tiếp cận chính: dựa trên cảm biến/thiết bị đeo và dựa trên thị giác máy tính. Trong đề án này, chúng tôi tập trung vào hướng tiếp cận dựa vào bộ khung xương và trên thị giác máy tính, vốn có tiềm năng ứng dụng rộng rãi hơn do không yêu cầu phần cứng chuyên dụng.

2.1 Phương pháp dựa trên video/hình ảnh (RGB-based)

Trước kỷ nguyên của Học sâu, các nhà nghiên cứu chủ yếu dựa vào các đặc trưng thủ công để biểu diễn thông tin hình ảnh kết hợp với các bộ phân loại như SVM (Support Vector Machines), KNN (K-Nearest Neighbors), Decision Trees, HMM [26]... Tuy phương pháp RGB-based giữa được toàn bộ thông tin (dáng bàn tay, biểu cảm...), nhưng nó rất dễ bị nhiễu bởi background, ánh sáng, và yêu cầu tài nguyên lớn để tính toán...

Vào thời kỳ phát triển của Học sâu, các mô hình CNN[17] và RNN[22] được áp dụng trực tiếp lên chuỗi ảnh RGB. Ví dụ, công trình nghiên cứu của Huang và Chouvatut (2024) [8] đã đề xuất sử dụng CNN kết hợp với LSTM để học đặc trưng không gian và thời gian cho nhận dạng cử chỉ tay. Hay bài nghiên cứu của Karen và Andrew [24] đã triển khai mô hình theo hướng Two-Stream CNN cho bài toán nhận diện hành động, sau đó được ứng dụng sang nhận diện ngôn ngữ ký hiệu.

2.2 Phương pháp dựa trên bộ xương (Pose-based)

Khác với phương pháp dựa trên RGB gốc, hướng tiếp cận dựa trên bộ xương người (pose-based) chỉ tập trung vào các tọa độ khớp (keypoints) của cơ thể, bàn tay... Mỗi khớp được thể hiện bằng một vector tọa độ 2D hay 3D, nhờ đó giảm đáng kể chi phí tính toán, kích thước dữ liệu so với video gốc nhưng vẫn giữ được thông tin quan trọng của động tác.

Dựa vào đó, một số cải tiến dựa trên bộ xương ra đời, như các node của đồ thị, với các cạnh nối biểu diễn mối quan hệ giải phẫu giữa chúng (ví dụ: bàn tay nối với cẳng tay, vai nối với cánh tay). Trên cơ sở đó, các mô hình Graph Convolutional Network (GCN) như nghiên cứu của Ushnish và đồng nghiệp (2024) [21] đã để lại một kết quả khá khả quan trong hướng nhận diện ngôn ngữ ký hiệu, và đặc biệt không thể kể đến cải tiến Spatial-Temporal GCN (ST-GCN) tiêu biểu là nghiên cứu vào năm 2018 của Sijie Yan và các đồng nghiệp [28].

Với hướng tiếp cận dựa vào bộ xương người, đã phần nào giải quyết được vấn đề của RGB như giảm nhiễu một cách rõ ràng, cực kỳ hiệu quả với bộ dữ liệu lớn, và nó hoàn toàn tập trung vào động tác và cấu trúc của không gian-thời gian của cử chỉ. Tuy nhiên, hạn chế của cách tiếp cận này là mất

thông tin chi tiết như hình dáng ngón tay, biểu cảm khuôn mặt hay ngữ cảnh môi trường, vốn đôi khi đóng vai trò quan trọng trong ngôn ngữ ký hiệu.

2.3 Phương pháp lai

Phương pháp lai trong nhận diện ngôn ngữ ký hiệu thường kết hợp các kỹ thuật học sâu như CNN (Convolutional Neural Networks), GCN (Graph Convolutional Networks) cho dữ liệu dạng bộ xương, hay các mô hình thời gian như LSTM (Long Short-Term Memory), HMM (Hidden Markov Models) để xử lý chuỗi cử động. Tiêu biểu cho loại mô hình lai này là mô hình Uni-Sign [16]. Mô hình kết hợp dữ liệu chuỗi ảnh RGB và dữ liệu khung xương và đã đánh dấu một mốc quan trọng trong lĩnh vực này.

2.4 Nghiên cứu liên quan đến bộ dữ liệu WLASL100

Bộ dữ liệu WLASL100 là một tập con của WLASL gồm 100 gloss, và được sử dụng rộng rãi trong nhiều nghiên cứu nhờ quy mô vừa phải và tính đa dạng cao.

Bảng 2.1: Các nghiên cứu tiêu biểu trên bộ dữ liệu WLASL100

Tác giả/Năm	Mô hình	Top-1 Acc.
Li et al. (2020) [14]	I3D / Pose-TGCN	~65.89% / 55.43%
Boháček & Hruš (2022) [1]	SPOTER	63.18%
Brettmann et al. (2025) [2]	Video ViT	75.58%
Pu et al. (2025) [18]	Siformer	86.50%

2.5 Nghiên cứu liên quan đến bộ dữ liệu LSA64

Bộ dữ liệu LSA64 xây dựng cho ngôn ngữ ký hiệu Argentina với 64 lớp cử chỉ tay. LSA64 cung cấp tập dữ liệu chuẩn cho các nghiên cứu nhận diện ký hiệu bằng chữ cái, nhờ dữ liệu gọn nhẹ, đa dạng về người thực hiện.

Bảng 2.2: Các nghiên cứu tiêu biểu trên bộ dữ liệu LSA64


Mô hình	Top-1 Acc.
DeepSign CNN [23]	96.00%
LSTM + LDS [13]	98.09%
I3D [9]	98.91%
SPOTER [1]	99.52% (100.00%)

Chương 3

Phương pháp


3.1 Tiền xử lý

Như đã đề cập ở trên, bộ dữ liệu được sử dụng để nghiên cứu chính trong báo cáo này là WLASL100. WLASL100 gồm có 100 từ phổ biến nhất, gồm 2038 video, và có độ dài tối thiểu là 12 khung hình, tối đa là 203 khung hình.



Hình 3.1: Điểm mốc của bàn tay


Hình 3.1 minh họa 21 điểm mốc của bàn tay. Mỗi điểm được đánh số từ 0 đến 20, trong đó điểm 0 là cổ tay, các điểm còn lại tương ứng với các khớp và đầu ngón tay. Các tọa độ này sẽ được sử dụng làm đặc trưng cho việc huấn luyện mô hình nhận dạng động tác.



Hình 3.2: Điểm mốc của cơ thể

Hình 3.2 minh họa các điểm của nửa phần trên của thân được hệ thống ước tính khung xương phát hiện. Các điểm bao gồm cổ, vai, khuỷu tay, cổ tay cũng như các điểm trên khuôn mặt như mũi, mắt và tai. Thông tin tọa độ của những điểm này được sử dụng làm đặc trưng hình học, kết hợp với điểm mốc của bàn tay để mô tả đầy đủ các động tác trong ngôn ngữ ký hiệu.

Với mỗi khung hình, hệ thống trích xuất mỗi bàn tay 21 điểm mốc và 12 điểm của nửa trên cơ thể. Các tọa độ này được chuẩn hóa về $[0;1]$ theo tỷ lệ của khung chứa bao quanh bộ phận đó theo công thức:



$$\begin{cases} x'_i = \frac{x_i - x_{\text{boundingBox}}}{W_{\text{boundingBox}}} \\ y'_i = \frac{y_i - y_{\text{boundingBox}}}{H_{\text{boundingBox}}} \end{cases} \quad (3.1)$$

Trong đó:

(x'_i, y'_i) : Tọa độ đã chuẩn hóa của điểm mốc i .

(x_i, y_i) : Tọa độ ban đầu của điểm i trong hệ trục ảnh (tính theo pixel).

$(x_{\text{boundingBox}}, y_{\text{boundingBox}})$: Tọa độ góc trên bên trái của bounding box.

$W_{\text{boundingBox}}, H_{\text{boundingBox}}$: Chiều rộng và chiều cao của bounding box.

Hình 3.3: Chuẩn hóa dữ liệu

Quá trình chuẩn hóa các điểm khớp này giúp loại bỏ sự khác biệt về tỷ lệ và vị trí của bàn tay giữa các khung hình hoặc giữa các đối tượng khác nhau. Nhờ vậy, mô hình học máy sẽ tập trung

vào hình dạng và động tác của bàn tay mà không bị ảnh hưởng bởi khoảng cách tới camera hay kích thước bàn tay của mỗi người.

Đối với tập dữ liệu WLASL100, mặc dù số lượng từ vựng chỉ dừng ở mức 2038 video biểu diễn 100 từ, số lượng giao động từ 18 đến 40 video, điều này cho thấy rằng tính đa dạng và sự phân phối không đồng đều của dữ liệu. Sự mất cân bằng này có thể làm cho mô hình bị sai lệch hoặc bị thiên vị. Dữ liệu trong lĩnh vực nhận dạng ngôn ngữ ký hiệu vốn đã khan hiếm, nên việc loại bỏ trực tiếp các video để tạo sự cân bằng giữa các lớp là không phù hợp. Chính vì thế tôi quyết định sử dụng kỹ thuật lấy mẫu bằng phương pháp SMOTE [4] là phương pháp lấy mẫu nổi tiếng nhất. SMOTE sử dụng thuật toán K-nearest neighbours để xác định các mẫu lân cận thuộc lớp thiểu số và sinh ra mẫu mới từ các mẫu hàng xóm.

Trước khi sử dụng SMOTE, tôi đã chuẩn hóa số lượng khung hình của mỗi video. Ở quá trình chuẩn hóa số lượng khung hình này, tôi đã chỉnh số lượng khung hình là 204 khung cho mỗi video, bằng cách thêm số 0 vào ở cuối nếu video đó không đủ 204 khung hình. Sau đó, tôi xác định lớp có số lượng nhiều nhất trong bộ dữ liệu là N . SMOTE có thể được biểu diễn qua công thức sau:

$$x'_i = x_i + w(x_k - x_i) \quad (3.2)$$

Trong đó:

- x'_i Mẫu dữ liệu mới được tạo ra bằng cách nội suy giữa x_i và x_k .
- x_i Mẫu gốc cần được nhân bản (sample).
- w Hệ số ngẫu nhiên được chọn trong đoạn $[0, 1]$.
- x_k Một mẫu khác được chọn từ tập láng giềng gần của x_i .


Tóm lại, phương pháp SMOTE giúp cân bằng số lượng mẫu giữa các lớp của bộ dữ liệu WLASL100 mà tôi đang dùng để xây dựng mô hình, từ đó giảm thiểu hiện tượng thiên vị trong quá trình huấn luyện mô hình.

3.2 Chỉnh khớp tay theo động lực học

Sau khi chuẩn hóa các tọa độ trích xuất, dữ liệu vẫn có thể xuất hiện những sai lệch nhỏ do rung lắc, lỗi nhận dạng hoặc tư thế không thực tế của bàn tay hay cơ thể. Để giải quyết sai lệch này, tôi đã tích hợp cơ chế điều chỉnh các khớp theo giải phẫu học, cụ thể là chuyển động dạng-khép, và duỗi-gập của các ngón tay, như minh họa phía dưới, đã được nghiên cứu đầy đủ trong giải phẫu, được trích dẫn từ [5, 20, 10].

Bảng 3.1: Các ràng buộc về dạng - khớp và duỗi - gấp được trích dẫn từ [5, 20, 10].

Chuyển động	Khớp	Tối thiểu (°)	Tối đa (°)
Dạng và khớp	Thumb CMC	0	45
	Thumb MCP	-7	12
	Các MCP khác	-15	15
	Thumb CMC	-20	45
Gập và duỗi	Thumb MCP	0	80
	Thumb IP	-30	90
	Các MCP khác	-40	90
	Các PIP khác	0	130
	Các DIP khác	-30	90



Hình 3.4: Ví dụ về sự gập-duỗi, dạng-khép của bàn tay được trích dẫn từ [5, 20, 3].

Việc điều chỉnh áp dụng các ràng buộc ở bảng 3.1 và được thể hiện thành các công thức sau:

$$\theta_i = \cos^{-1}\left(\frac{P_i(t) \cdot P_r(t)}{\|P_i(t)\|_2 \cdot \|P_r(t)\|_2}\right) \quad (3.3)$$

$$\varepsilon_i^\theta = f(\theta_i) = \begin{cases} \theta_{min} - \theta_i & \text{khi } \theta_i < \theta_{min} \\ 0 & \text{khi } \theta_{min} \leq \theta_i \leq \theta_{max} \\ \theta_i - \theta_{max} & \text{khi } \theta_{max} < \theta_i \end{cases} \quad (3.4)$$

$$P_i(t)' = R(\alpha \cdot \varepsilon_i^\theta) \cdot P_i(t), \text{ nếu } \varepsilon_i^\theta > 0 \quad (3.5)$$

Trong đó:


- θ_i Góc giữa vector $P_i(t)$ và $P_r(t)$ tại thời điểm t .
- $P_i(t)$ Vector đặc trưng tại khớp hoặc điểm mốc thứ i ở thời điểm t .
- $P_r(t)$ Vector tham chiếu tại thời điểm t .
- $P_i(t) \cdot P_r(t)$ Tích vô hướng giữa hai vector.
- $\|P_i(t)\|_2$ Độ dài của vector $P_i(t)$.
- $\|P_r(t)\|_2$ Độ dài của vector $P_r(t)$.
- α Tỷ lệ cần điều chỉnh.

3.3 Cơ chế tách biệt các bộ phận cơ thể

Trong nhận dạng ngôn ngữ ký hiệu, độ phức tạp khi biểu diễn các ký hiệu là khác nhau, việc gom các đặc trưng lại để tiến hành học dẫn đến hiệu quả không tốt khi một bộ phận nào đó không tham gia vào biểu diễn. Trong kiến trúc này, tôi đề xuất việc tách các bộ phận cơ thể thành các phần khác nhau để mỗi phần có thể tập trung nắm ngữ cảnh thời gian-không gian của chính bộ phận đó. Tuy nhiên, việc mỗi bộ phận được tách ra riêng để học riêng lẻ khiến cho mối quan hệ giữa các bộ phận bị hạn chế, trong quá trình nghiên cứu tôi cảm thấy rằng giữa 2 bàn tay có một mối quan hệ khá

lớn và chặt chẽ, vì vậy tôi đã thêm cơ chế giao tiếp giữa các bộ phận (được trình bày ở 3.4) với nhau trước khi chúng được tiến đến quá trình mã hóa/giải mã.

Ngoài ra, tôi đã tham khảo thêm một thiết kế mã hóa vị trí theo khung hình cho mô hình để tích hợp thêm thông tin vị trí vào chuỗi và tận dụng cơ chế ProbSparse Attention giúp tính toán một cách hiệu quả.



Hình 3.5: Thành phần cốt lõi của kiến trúc mà tôi đề xuất.

- (1) Là quá trình hiệu chỉnh động lực học của tay.
- (2) Là cơ chế giao tiếp giữa các bộ phận nhằm trao đổi thông tin ở một số bộ phận quan trọng.
- (3) Khối phân tách các bộ phận thành các luồng để nắm bắt bối cảnh trong giai đoạn mã hóa.
- (4) Bộ phân loại nội bộ ở mỗi lớp.

3.3.1 Mã hóa vị trí theo khung hình

Trong kiến trúc Transformer, cơ chế Self-Attention chỉ khai thác mối quan hệ nội dung giữa các phần tử trong chuỗi mà không có khả năng phân biệt thứ tự lần lượt của mỗi phần tử. Mà dữ liệu đầu vào của tôi là chuỗi khung hình có thứ tự theo thời gian không thể thay đổi được, nên tôi đã mã hóa vị trí các khung hình, trong đó mỗi khung hình được gán thêm một vectơ biểu diễn vị trí. Việc mã hóa được thể hiện qua công thức:

$$X' = X + P \quad (3.6)$$

$$\text{Điều kiện: } \begin{cases} P_{i,i} = P_{i,j} \\ P_{i,i} \neq P_{j,i} \\ i \neq j \end{cases}$$

Trong đó: X' : Ma trận embedding sau khi được mã hóa vị trí khung hình
 X : Ma trận embedding đầu vào của chuỗi khung hình
 P : Ma trận mã hoá vị trí

Tức là, mọi video trong một khung hình thì giá trị mã hóa vị trí là bằng nhau, nhưng giá trị mã hóa giữa các khung hình là khác nhau. Cách tiếp cận này đảm bảo rằng các giá trị vị trí thay đổi qua các khung hình nhưng vẫn nhất quán trong một khung hình.

3.3.2 Cơ chế ProbSparse Attention [27, 18]

Cơ chế ProbSparse Attention được Zhou et al. (2021) [27] đề xuất nhằm giải quyết hạn chế về chi phí tính toán của Self-Attention truyền thống trong Transformer. Trong báo cáo này tôi đã sử dụng cơ chế ProbSparse Attention trên sự tham khảo mô hình Siformer [18]. Với cách tiếp cận của ProbSparse Attention đã tập trung vào các thông tin cốt lõi nhất, bỏ đi các phần thông tin không cần thiết, do đó chi phí tính toán giảm đi một cách đáng kể và hiệu quả. ProbSparse được biểu diễn bằng phương trình sau:

$$A(Q, K, V) = softmax(\frac{\overline{Q}K^T}{\sqrt{d}})V \quad (3.7)$$

Trong đó:

$Q, K, V \in \mathbb{R}^{T \times d}$ Lần lượt là ma trận *query*, *key*, và *value*, với T là số lượng khung hình
 $\overline{Q}$ Có cùng kích thước với Q sau khi đã áp dụng cơ chế thưa.
 d Số chiều đặc trưng, sử dụng trong phép chuẩn hoá để tránh giá trị dot product quá lớn.

Phép đo độ thưa:

$$M(q_i, K) = \max_j \left\{ \frac{q_i k_j^T}{\sqrt{d}} \right\} - \frac{1}{L_k} \sum_{j=1}^{L_k} \frac{q_i k_j^T}{\sqrt{d}} \quad (3.8)$$

Trong đó:

- $q_i \in \mathbb{R}^d$ Vector query tại vị trí i trong chuỗi đầu vào.
- $k_j \in \mathbb{R}^d$ Vector key tại vị trí j .
- d Số chiều đặc trưng, sử dụng trong phép chuẩn hoá để tránh giá trị dot product quá lớn.
- L_k Số lượng key được xét cho một query q_i .
- $M(q_i, K)$ Độ đo mức độ thưa (sparsity measurement) — biểu thị sự khác biệt giữa giá trị attention mạnh nhất và giá trị attention trung bình của q_i với tất cả các key.

Như tôi đã trình bày, cơ chế ProbSparse tập trung vào trong phân phối Attention, chỉ một số ít các truy vấn (*queries*) mới thực sự mang tính quyết định trong việc hình thành mối quan hệ. Chính các truy vấn này có xu hướng tạo ra sự phân biệt rõ rệt giữa các trọng số Attention và được phản ánh qua thước đo độ thưa $M(q_i, K)$. Vì vậy, bằng cách lựa chọn những truy vấn có giá trị $M(q_i, K)$ lớn, để ProbSparse loại bỏ phần lớn các truy vấn không quan trọng, từ đó rút gọn chi phí tính toán.

Đáng chú ý, ProbSparse làm giảm chi phí tính toán một cách hiệu quả, từ $\mathcal{O}(L^2)$ của cơ chế Self-Attention chuẩn xuống còn $\mathcal{O}(L \log L)$ mà vẫn duy trì chất lượng biểu diễn. Điều này rất phù hợp cho các mô hình xử lý chuỗi dài như các mô hình nhận dạng ngôn ngữ ký hiệu.

3.3.3 Tách biệt các bộ phận

Trong các mô hình nhận diện ngôn ngữ ký hiệu dựa trên bộ khung xương, dữ liệu thường được biểu diễn dưới dạng tập hợp các khớp của cơ thể. Tuy nhiên, vai trò của các khớp có thể không giống nhau, chuyển động của bàn tay thường mang nhiều thông tin ngữ nghĩa hơn so với thân. Vì vậy, nếu toàn bộ các khớp được xử lý trong một luồng duy nhất, nhiều ở một số khớp hay bộ phận có thể làm ảnh hưởng đến bộ phận khác và làm giảm độ tin cậy trong nhận dạng tổng thể.

Để giải quyết vấn đề này, nghiên cứu này tôi đề xuất *cơ chế tách biệt các bộ phận cơ thể*, trong đó bộ xương được chia thành 3 cụm giải phẫu chính: tay trái - tay phải - thân trên. Mỗi cụm được xử lý độc lập và các luồng đó lần lượt đi qua khối (2) *Communicating*, sau đó là khối (3) *Encoding* giúp hạn chế lan truyền sai lệch và không những cho phép học được các ngữ cảnh riêng của chính bộ phận đó, mà còn học được có thể học được thông tin của bộ phận khác thông qua khối (2) *Communicating*. Sau đó, các đặc trưng được nối lại:

$$F_{map} = \text{concat}(F_l, F_r, F_b) \in \mathbb{R}^{(L_l+L_r+L_b) \times d} \quad (3.9)$$

Trong đó:

L_l, L_r, L_b	Lần lượt là độ dài khung hình của tay trái, tay phải, phần thân.
$F_l \in \mathbb{R}^{L_l \times d}$	Ma trận đặc trưng của tay trái.
$F_r \in \mathbb{R}^{L_r \times d}$	Ma trận đặc trưng của tay phải.
$F_b \in \mathbb{R}^{L_b \times d}$	Ma trận đặc trưng của thân người.
$concat(\cdot)$	Phép nối (gộp) các ma trận F_l, F_r, F_b thành một ma trận duy nhất.
d	Số chiều đặc trưng (feature dimension) thống nhất cho cả ba bộ phận.
F_{map}	Ma trận đặc trưng hợp nhất, có kích thước $(L_l + L_r + L_b) \times d$.

Tóm lại, ý tưởng cốt lõi của cơ chế này là tách riêng ba bộ phận tay trái, tay phải và thân trên để giao tiếp và mã hóa, sau đó mới ghép chúng lại đưa vào bộ giải mã dựa trên Class Query [1]. Điều này giúp mô hình tập trung tốt hơn vào từng bộ phận và giảm thiểu ảnh hưởng khi một số dữ liệu bị thiếu.

3.4 Giao tiếp giữa các bộ phận

Trong nhận diện ngôn ngữ ký hiệu, sự tương tác của hai tay như một hệ thống phối hợp chặt chẽ và mang lượng thông tin là rất lớn. Ngược lại, khung xương ở phần thân trên với 5 tọa độ của khuôn mặt và 7 tọa độ của vai-tay, với tất cả đặc trưng tọa độ này chúng mang ít thông tin. Do đó, trong mô hình tôi tập trung vào việc tối ưu cơ chế trao đổi thông tin giữa hai tay, trong khi phần thân trên chỉ cung cấp một khung xương để tham chiếu. Khối (2) *Communicating* là một bộ phận cốt lõi trong mô hình của tôi, đảm nhận vai trò kết nối và làm giàu ngữ cảnh giữa các bộ phận. Tại đây, các bộ phận không chỉ sử dụng cơ chế ProbSparse để tìm hiểu các thông tin của chính bộ phận đó, mà còn dùng cơ chế *Multi-head Attention* [11] để học thêm các ngữ nghĩa của bộ phận khác. Ở Attention này, vectơ đặc trưng của bộ phận thứ nhất (bộ phận nhận thông tin) đóng vai trò làm truy vấn, còn bộ phận thứ 2 (đóng vai trò cung cấp thông tin cho bộ phận thứ nhất) làm *khóa* (*key*) và giá trị (*value*). Nhờ đó, bộ phận thứ nhất sẽ được bổ sung bởi thông tin của bộ phận thứ 2. Khi mở rộng sang nhiều head, ta có cơ chế *Multi-head Attention* [11]:

$$MHA(Q, K, V) = \underbrace{\text{Concat}(\text{head}^1, \dots, \text{head}^h)}_{[n_q \times (hd_v)]} \cdot W_O, \quad (3.10)$$

$$\text{head}^i = \text{Attention}(Q \cdot W_Q^i, K \cdot W_K^i, V \cdot W_V^i), \quad (3.11)$$

Trong đó:

$Q \in \mathbb{R}^{n_q \times d_{\text{model}}}$	Ma trận đặc trưng của bộ phận thứ nhất.
$K \in \mathbb{R}^{n_k \times d_{\text{model}}}$	Ma trận đặc trưng của bộ phận thứ hai.
$V \in \mathbb{R}^{n_v \times d_{\text{model}}}$	Cùng nguồn với K , chứa thông tin để tổng hợp kết quả.
$W_Q^i \in \mathbb{R}^{d_{\text{model}} \times d_k/h}$	Trọng số chiều query vào không gian con.
$W_K^i \in \mathbb{R}^{d_{\text{model}} \times d_k/h}$	Trọng số chiều key vào không gian con.
$W_V^i \in \mathbb{R}^{d_{\text{model}} \times d_v/h}$	Trọng số chiều value vào không gian con.
$W_O \in \mathbb{R}^{(hd_v) \times d_{\text{model}}}$	Ma trận chiếu tuyến tính để đưa kết quả trả về.

Trong khuôn khổ nhận dạng ngôn ngữ ký hiệu, cơ chế giao tiếp này được thiết kế để cân bằng giữa việc duy trì tính độc lập của các luồng bộ phận và việc nắm bắt được ngữ cảnh của nhau.

3.5 Cơ chế suy luận thích ứng đầu vào [18]

Như chúng ta đã biết, ngôn ngữ ký hiệu là cầu nối cho người khiếm thính, khiếm ngôn giao tiếp với cộng đồng, cũng như ngôn ngữ bình thường của chúng ta, trong ngôn ngữ phổ thông không phải bất kỳ từ ngữ, câu nào cũng khó phát âm như nhau. Tương tự đó, ở ngôn ngữ ký hiệu không phải ký hiệu nào cũng khó biểu diễn, có những mẫu ký hiệu được phân loại chính xác với các đặc trưng ở các tầng nông, trong khi có những ký hiệu được phân loại phức tạp ở sâu hơn. Nếu tất cả chúng bắt buộc phải đi qua toàn bộ các tầng thì mô hình sẽ kém hiệu quả về mặt chi phí tính toán và gây nên hiện tượng suy nghĩ quá mức.

Để khắc phục tình trạng này, trong mô hình *Siformer* [18] đã lấy ý tưởng từ [30] và đã đề xuất cơ chế suy luận một cách thông minh. Cụ thể, tại mỗi tầng của bộ mã hóa/giải mã có thêm một biến cờ để theo dõi sự dự đoán trung gian. Nếu trong N bước liên tiếp mô hình dự đoán cùng một kết quả thì sẽ dừng lại và trả ra kết quả dự đoán đó, thay vì phải đi hết tất cả các tầng sâu hơn. Bộ đếm của biến cờ đó được biểu diễn qua công thức toán học như sau:

$$cnt_i = \begin{cases} cnt_{i-1} + 1 & \text{khi } y_i = y_{i-1} \\ 0 & \text{khi } y_i \neq y_{i-1} \vee i = 1 \end{cases}, \quad (3.12)$$

$$y_i = \arg \max(Cls_i(h_i)), \quad (3.13)$$

Trong đó:

y_i và y_{i-1}	Là nhãn dự đoán tại tầng hiện tại và tầng trước đó.
cnt_i và cnt_{i-1}	Là bộ đếm tại tầng hiện tại và tầng trước đó.
Cls_i	Là một bộ phân loại nội bộ độc lập được gắn vào cuối tầng i .
h_i	Là vector trạng thái ẩn ở đầu ra của tầng i .

Chương 4

Thực nghiệm

4.1 Chi tiết thực nghiệm

4.1.1 Tập dữ liệu

Như tôi đã đề cập ở trên, ở phần thực nghiệm tôi muốn tập trung vào một bộ dữ liệu chính đó là WLASL100 - là một tập con của bộ dữ liệu WLASL [14]. Tập dữ liệu WLASL100 có 2038 video thể hiện 100 từ, được thực hiện bởi 97 người phiên dịch. Tôi đã thực hiện áp dụng kỹ thuật SMOTE trên tập dữ liệu này để tránh sự mất cân bằng dữ liệu. Trước khi thực hiện SMOTE, tôi đã tiến hành lấy 8 video của mỗi từ tách riêng làm tập dữ liệu để kiểm tra. Sau khi áp dụng SMOTE, tập dữ liệu của tôi có được 3200 mẫu, và tôi chia 80% tương đương với 2560 mẫu dùng để đào tạo, và 640 mẫu còn lại dùng để kiểm định.

Tập dữ liệu thứ hai là LSA64, vì tập dữ liệu này ổn định về sự cân bằng rồi. Nên ở bộ này tôi đã chia 80% cho Train và 20% cho Test.

4.1.2 Cấu hình thiết bị thực nghiệm

Các thí nghiệm được thực hiện trên máy tính cá nhân có hệ điều hành Windows 11 Home với cấu hình phần cứng:

- CPU 12th Gen Intel(R) Core(TM) i5-12450HX (2.40GHz, 8 cores)
- RAM 16GB
- GPU NVIDIA RTX 3050 6GB

4.1.3 Các tham số huấn luyện

Tham số huấn luyện:

- Batch size: 24.
- Số epoch: 100.
- Tối ưu hoá: AdamW, learning rate 1×10^{-4} , $\beta = (0.9, 0.999)$, weight decay 1×10^{-8} .
- Hàm mất mát: CrossEntropyLoss (label smoothing 0.1).
- Scheduler: CosineAnnealingLR, $T_{\max} = 100$, $\eta_{\min} = 0$.

Kỹ thuật tăng cường dữ liệu: thêm nhiễu Gaussian với $\mu = 0$, $\sigma = 0.001$.

4.2 Phân tích hiệu chỉnh động lực học của bàn tay [18]

Điều chỉnh động lực học là một trong những đóng góp quan trọng của mô hình Siformer [18] để giải quyết vấn đề bộ khung xương phi thực tế trong nhận diện ngôn ngữ ký hiệu do Pu và các cộng sự đã giới thiệu trong [18].

Để đánh giá hiệu quả của đề xuất này, các tác giả đã tiến hành một loạt các phân tích và đưa ra các số liệu là kết quả của quá trình thực nghiệm của họ để tìm ra giá trị α tối ưu nhất và áp dụng trong công thức 3.5, một hệ số kiểm soát mức độ hiệu chỉnh. Nghiên cứu đã khảo sát các giá trị α trong khoảng từ 0 (không hiệu chỉnh) đến 1 (hiệu chỉnh hoàn toàn).

Và kết quả thực nghiệm của họ đã cho thấy hiệu suất của mô hình đạt mức cao nhất khi $\alpha = 0.4$. Dựa trên kết quả này, nghiên cứu của tôi sẽ sử dụng $\alpha = 0.4$ làm giá trị cơ sở cho thành phần hiệu chỉnh tư thế.

4.3 Hiệu quả của số lượng lớp *Communicating - Encoder - Decoder*

Để xác định các phân tích trên là đúng đắn, tôi đã tiến hành loạt các thí nghiệm nhằm khảo sát sự ảnh hưởng của số lượng lớp trong các thành phần chính: *Communicating*, *Encoder*, *Decoder*. Kết quả được trình bày ở trong Bảng 4.1. Trong các thí nghiệm này, tôi đã thay đổi số lượng lớp của mỗi thành phần trong khi giữ nguyên giá trị các thành phần còn lại để đánh giá, điều chỉnh mô hình:

Bảng 4.1: Hiệu quả của số lượng lớp trên tập dữ liệu WLASL100

COMMUNICATING	ENCODER	DECODER	ACCURACY (%)
Sự thay đổi lớp <i>Communicating</i>			
1	3	2	87.00
2	3	2	84.375
3	3	2	84.75
4	3	2	82.375
Sự thay đổi lớp <i>Encoder</i>			
1	2	2	86.75
1	3	2	87.00 (TH₁)
1	4	2	84.75
1	5	2	84.75
Sự thay đổi lớp <i>Decoder</i>			
1	3	1	85.00
1	3	2	87.00
1	3	3	85.00
1	3	4	87.88%(TH₂)
1	3	5	86.125

Đầu tiên, tôi đã khảo sát số lượng của số lớp *Communicating*, kết quả cho thấy với 1 lớp *Communicating* mang lại độ chính xác cao nhất là 87%. Khi tăng số lượng lên, mô hình có sự không ổn định. Điều này chính tỏ, sử dụng nhiều lớp *Communicating* không mang lại nhiều lợi ích mà còn có thể gây nhiễu trong quá trình học.

Tiếp theo, khảo sát về số lượng lớp *Encoder*. Trong nghiên cứu của Pu và đồng nghiệp [18] cũng

đã khảo sát sự biến thiên của lớp *Encoder* này, trong phần thực nghiệm tôi cũng đã tiến hành chạy thử và nhận được kết quả khá ấn tượng. Ở các cấu hình giống với nghiên cứu gốc, kết quả là độ chính xác cao hơn cả Siformer nguyên nhân chính là cơ chế giao tiếp giữa các bộ phận hoạt động khá hiệu quả và tạo nên sự khác biệt về độ chính xác.

Cuối cùng, lớp *Decoder*. Báo cáo của mô hình Siformer [18] cũng đã khảo sát và tôi cũng đã tiến hành khảo sát trên một số tham số cấu hình giống tác giả. Qua kết quả số liệu, mối quan hệ giữa hai tay khi biểu diễn ngôn ngữ ký hiệu là rất chặt chẽ.

4.4 Đánh giá hiệu quả của cơ chế suy luận thích ứng đầu vào

Để chọn được một giá trị *patience* có kết quả tốt, tôi đã tiến hành khảo sát tham số *patience* chung cho cả hai khối *Encoder* và *Decoder* - giá trị đại diện cho số lần để mô hình chờ thêm thông tin trước khi đưa ra dự đoán cuối cùng. Thí nghiệm được tiến hành trên hai cấu hình được đánh dấu ở Bảng 4.1.

Bảng 4.2: Khảo sát giá trị *patience* trên WLASL100
($patience_{encoder}=patience_{decoder}$)

	Giá trị <i>patience</i>	Top-1 Độ chính xác (%)
TH ₁	1	87.125
	2	87.00
TH ₂	1	87.625
	2	87.88%
	3	87.88%

Kết quả trong Bảng 4.1 cho thấy, với thông số của TH₁, giá trị *patience* ảnh hưởng không nhiều đến độ chính xác của mô hình, $patience=1$ là một lựa chọn tối ưu hóa nhất. Giống TH₁, các tham số cấu hình TH₂ cũng không có sự thay đổi quá lớn về độ chính xác, $patience=2$ là lựa chọn hợp lý.

Mô hình Siformer [18] cũng đã khảo sát giá trị *patience*, kết hợp với Bảng 4.1 mà tôi khảo sát. Tất cả các kết quả đều cao hơn so với mô hình gốc. Điều này càng chứng minh cơ chế giao tiếp giữa các bộ phận là tốt, giúp cho mô hình ổn định hơn và không phụ thuộc quá nhiều vào việc tinh chỉnh tham số *patience*.

Vì số lượng lớp của khối *Encoder* và khối *Decoder* là khác nhau, và kích thước dữ liệu đầu vào của hai khối cũng khác nhau, nên việc dùng chung 1 giá trị *patience* cho cả 2 khối này thật sự không hợp lý và chưa đủ để tối ưu hóa hiệu suất tính toán. Ở bảng 4.2 tôi đã khảo sát giá trị $patience_{encoder}=1$, và $patience_{decoder}=2$ để khảo sát cho cấu hình của TH₁ và TH₂:

Bảng 4.3: Khảo sát giá trị $patience$ riêng cho từng khối trên WLASL100

	Giá trị $patience_{encoder}$	Giá trị $patience_{decoder}$	Top-1 Độ chính xác (%)
TH ₁	1	2	87.125
TH ₂	1	2	87.88%

Với kết quả khảo sát ở bảng 4.3, tôi đã không dùng chung giá trị $patience$ cho cả hai khối *Encoder* và *Decoder* thì độ chính xác vẫn không có sự thay đổi. Tuy nhiên, sự khác biệt ở đây là số lượng thoát sớm của dữ liệu, cụ thể:

Bảng 4.4: Bảng thống kê số mẫu thử nghiệm thoát sớm của Encoder.
(Cấu hình TH₂: $1 \times Communicating$ | $3 \times Encoder$ | $4 \times Decoder$)

Giá trị $patience_{encoder}$	Giá trị $patience_{decoder}$	Test	Train	Validation
1	2	109/800	338/2560	82/640
2	2	0/800	1/2560	0/640

Qua bảng 4.4, cùng độ chính xác là 87.88%. nhưng khi nhìn về hiệu suất thì việc dùng chung $patience=2$ lại có hiệu suất thấp hơn so với việc dùng riêng $patience_{encoder}=1$ và $patience_{encoder}=2$. Ở bài báo cáo gốc của mô hình Siformer, tác giả thống kê được có khoảng 5% mẫu số liệu được thoát sớm và tiết kiệm được khoảng 26% chi phí tính toán trên tập dữ liệu Test, ở đây cũng trên tập Test đã có 13.6% mẫu số liệu thoát, và tiết kiệm hơn gấp đôi chi phí tính toán. Điều này cho thấy cơ chế suy luận thích ứng đầu vào hoạt động hiệu quả và thông minh hơn khi tham số $patience$ hợp lý.

Việc dùng cơ chế suy luận thích ứng đầu vào giúp mô hình cải thiện hiệu suất tính toán, để làm rõ lợi ích này tôi đã khảo sát trên mô hình có cấu hình của TH₂ với tham số $patience_{encoder}=1$, $patience_{decoder}=2$:

Bảng 4.5: Hiệu quả của suy luận thích ứng theo đầu vào.
Với giá trị $patience_{encoder}=1$, $patience_{decoder}=2$ và cấu hình TH₂

Tổng số mẫu	Tổng số mẫu dừng sớm	Số mẫu dừng ở 1 bộ phận	Số mẫu dừng ở 2 bộ phận	Số mẫu dừng ở 3 bộ phận
800 (Test)	109	104	5	—
2560 (Train)	338	329	9	—
640 (Validation)	82	80	2	—

Phần lớn các trường hợp dừng sớm ở 1 luồng bộ phận. Tuy nhiên, tỷ lệ tổng thể rất đáng để chú ý, cho thấy sau khi thêm giao tiếp giữa các luồng, thì chính cơ chế giao tiếp làm cho cơ chế suy luận này có thêm nhiều cơ sở để đưa ra quyết định dừng sớm khi độ tin cậy của dự đoán vừa đủ.

Để phân tích sâu hơn, tôi đã thực nghiệm thêm và đánh giá trong các trường hợp dừng sớm, thì số lượng bộ phận nào dừng nhiều, kết quả được thể hiện ở Bảng 4.6 phía dưới:

Bảng 4.6: Sự đóng góp của từng luồng bộ phận vào quyết định dừng sớm.
 Với giá trị $patience_{encoder}=1$, $patience_{decoder}=2$ và cấu hình TH₂

Tổng số mẫu	Tổng số mẫu dừng sớm	Luồng tay trái thoát sớm	Luồng tay phải thoát sớm	Luồng thân thoát sớm
800 (Test)	109	73	28	13
2560 (Train)	338	238	76	33
640 (Validation)	82	62	18	8

Xét riêng từng luồng bộ phận, có thể thấy luồng tay trái chi phối phần lớn trong việc kích hoạt cơ chế dừng sớm, tay phải đóng vai trò hỗ trợ hiệu quả cho tay trái. Do đó, việc khai thác đặc trưng kết hợp với giao tiếp giữa hai tay là một hướng đi chính xác. Ngược lại, luồng của phần thân ảnh hưởng rất nhỏ, cho thấy thông tin từ bộ phận này ít quan trọng hơn cho việc đưa ra quyết định dừng.

So với mô hình Siformer gốc, kết quả cho thấy cơ chế suy luận thích ứng đầu vào của mô hình mà tôi đề xuất hoạt động hiệu quả rất tốt. Trên cùng tập dữ liệu Test, mô hình gốc đạt được tỷ lệ dừng sớm là 5%, trong khi mô hình của tôi tỷ lệ dừng sớm trên 13.6%. Sự chênh lệch này giúp cho mô hình tiết kiệm một khoảng chi phí tính toán khổng lồ nhưng vẫn đạt được độ chính xác cao.

4.5 So sánh

Để đánh giá một cách khách quan về hiệu quả của những cải tiến mà tôi đã đề xuất, tôi đã tiến hành so sánh hiệu suất của mô hình của tôi với các công trình liên quan khác trên tập dữ liệu WLASL100. Bảng 4.7 ở phía dưới trình bày chi tiết kết quả so sánh các phương pháp RGB, phương pháp dựa trên khung xương, và phương pháp lai.

Bảng 4.7: So sánh các công trình trên tập dữ liệu WLASL100

Phương pháp	Số tham số (Triệu)	Top-1 Độ chính xác (%)	Top-5 Độ chính xác (%)
Phương pháp dựa trên RGB			
I3D [15]	12.35	65.89	84.11
TCK [15]	–	77.52	91.08
SignBERT+ [7]	–	84.11	96.51
Phương pháp dựa trên khung xương			
ST-GCN [25]	–	50.78	79.07
Pose-TGCN [15]	–	55.43	78.68
SPOTER [1]	5.92	63.18	–
SignBERT+ [7]	–	79.84	91.09
Siformer [18]	–	86.50	–
Của tôi	4	87.88	93.5
Phương pháp lai			
Fusion-3 [6]	–	75.67	86.00
Uni-Sign [16]	592	92.25	–

Mô hình tôi đã cải tiến dựa trên mô hình Siformer [18] đã đạt được độ chính xác **87.88%**. Kết

quả này không chỉ vượt qua mô hình Siformer gốc mà còn thiết lập một kỷ lục về Top-1 độ chính xác so với các mô hình nhận diện dựa trên ảnh màu hoặc dựa trên bộ khung xương. Sự vượt trội trong mô hình cải tiến này là bởi cơ chế giao tiếp giữa các luồng đặc trưng và cơ chế suy luận thích ứng đầu vào. Cơ chế giúp các luồng bộ phận không những hiểu thông tin mà chính mình đang mang, mà còn hiểu thêm thông tin của bộ phận khác. Đồng thời, mô hình tôi hướng đến là mô hình có thể áp dụng thực tiễn nên hiệu suất của mô hình cũng được cải tiến một cách hiệu quả. Nhờ đó, các chuyển động trong cơ thể được tương tác với nhau, mô hình nắm được những sắc thái chi tiết, tinh vi hơn. Điều này trực tiếp dẫn đến việc tăng cường độ chính xác, giảm chi phí tính toán trong phân loại.

So với các mô hình lai, độ chính xác 87.88% của tôi so với 92.25% của Uni-Sign là một khoảng cách khá lớn. Sự khác biệt lớn nhất giữa hai mô hình chính là độ chính xác và hiệu quả tính toán. Uni-Sign có khoảng 592 triệu tham số, tổn lượng chi phí khổng lồ vào tiền huấn luyện, mang lại một kết quả hàng đầu. Ngược lại, mô hình của tôi, có hơn 4 triệu tham số, và chú trọng về hiệu suất để hướng đến vấn đề thực tiễn cuộc sống. Điều này cho thấy mô hình của tôi khá phù hợp với thực tế, mở ra tiền năng ứng dụng vào thực tiễn.

Bảng 4.8: So sánh các công trình trên tập dữ liệu LSA64

Phương pháp	Top-1 Độ chính xác (%)
Phương pháp dựa trên RGB	
DeepSign CNN [23]	96.00
LSTM + LDS [13]	98.09
I3D [9]	98.91
MEMP [29]	99.06
Phương pháp dựa trên khung xương	
LSTM + DSC [12]	92.15
SPOTER [1]	99.52% (100.00)
Siformer [18]	99.84
Của tôi	99.84

Một số phương pháp cũ như LSTM+DSC đạt khoảng 92%, tuy nhiên, các mô hình mới như SPOTER và Siformer đã thể hiện sự vượt trội, thậm chí ngang bằng và cao hơn cả các mô hình của phương pháp RGB. Hơn nữa, mô hình Siformer và mô hình tôi cải tiến đã đạt được độ chính xác ngang bằng nhau 99.84%, chứng minh được kiến trúc của mô hình tôi là phù hợp.

Chương 5

Kết luận

5.1 Kết luận

Ngôn ngữ ký hiệu là phương tiện giao tiếp thiết yếu của cộng đồng người khiếm thính, khiếm ngôn. Tuy nhiên, không phải ai cũng có thể hiểu được các ký hiệu đó, việc thiếu các phương tiện để thông dịch ngôn ngữ ký hiệu làm một trong những khó khăn của người khiếm khuyết hòa nhập với cộng đồng. Trong thời đại trí tuệ nhân tạo phát triển, việc áp dụng thị giác máy tính vào nhận dạng ngôn ngữ ký hiệu làm cầu nối giao tiếp là một trong những hướng đi vô cùng thực tiễn.

Trong bài báo cáo này, tôi đã đưa ra một số đề xuất trong việc nhận dạng các ký hiệu từ video trong bộ dữ liệu WLASL100. Mô hình được xây dựng không quá phức tạp, không dựa vào hướng xử lý theo RGB, giúp giảm được độ phức tạp trong tính toán mà chỉ tập trung vào thông tin chuyển động của bộ khung xương trên cơ thể. Sau quá trình thực nghiệm, tôi đã phần nào chứng minh được phương pháp của mình có là đúng, được thể hiện qua độ chính xác trên tập dữ liệu WLASL100 là 87.88% và 99.84% trên tập dữ liệu LSA64. Theo nhận định của tôi, độ chính xác 87.88% trên WLASL100 hay 99.84% trên LSA64 là một kết quả chưa thật sự khả quan lắm, tuy nhiên nó sẽ tiền đề góp phần vào việc phát triển công nghệ thông dịch hỗ trợ cộng đồng người khiếm khuyết để xây dựng một hệ thống thông dịch tự động, thúc đẩy hòa nhập xã hội.

Qua quá trình tìm tòi, học hỏi để hoàn thành môn đồ án ngành này, tôi đã tích lũy rất nhiều kinh nghiệm, kỹ năng của ngành Công nghệ thông tin. Nắm vững các kỹ thuật xử lý ảnh và thị giác máy tính. Hoàn thiện về luồng suy nghĩ tư duy xây dựng phương pháp và đánh giá mô hình học sâu. Cũng như hiểu biết sâu hơn về ứng dụng AI để giải quyết các vấn đề thực tiễn cấp thiết.

5.2 Hướng phát triển

Với kết quả chưa thật sự kỳ vọng đúng tôi, trong tương lai tôi sẽ phát triển nó theo hướng:

- Kết hợp thông tin từ phương pháp RGB.
- Áp dụng các kỹ thuật, các mạng hiện đại khác như Graph Neural Networks, Temporal Convolutional Networks. . . .
- Ứng dụng mô hình và thực tế cho cộng đồng người khiếm khuyết.
- Tiến hành trên bộ dữ liệu của Việt Nam.

Tài liệu tham khảo

Tiếng Anh

- [1] Boháček, Matyáš and Hruz, Marek. “Sign pose-based transformer for word-level sign language recognition”. In: *Proceedings of the IEEE/CVF winter conference on applications of computer vision*. 2022, pp. 182–191.
- [2] Brettmann, Alexander et al. “Breaking the Barriers: Video Vision Transformers for Word-Level Sign Language Recognition”. In: *arXiv preprint arXiv:2504.07792* (2025).
- [3] Cabibihan, John-John et al. “Suitability of the openly accessible 3D printed prosthetic hands for war-wounded children”. In: *Frontiers in Robotics and AI* 7 (2021), p. 594196.
- [4] Elreedy, Dina and Atiya, Amir F. “A comprehensive analysis of synthetic minority oversampling technique (SMOTE) for handling class imbalance”. In: *Information Sciences* 505 (2019), pp. 32–64.
- [5] Hochschild, Jutta. *Functional anatomy for physical therapists*. Georg Thieme Verlag, 2016.
- [6] Hosain, Al Amin et al. “Hand pose guided 3d pooling for word-level sign language recognition”. In: *Proceedings of the IEEE/CVF winter conference on applications of computer vision*. 2021, pp. 3429–3439.
- [7] Hu, Hezhen et al. “SignBERT+: Hand-Model-Aware Self-Supervised Pre-Training for Sign Language Understanding”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.9 (2023), pp. 11221–11239. DOI: 10.1109/TPAMI.2023.3269220.
- [8] Huang, Jiayu and Chouvatut, Varin. “Video-based sign language recognition via resnet and lstm network”. In: *Journal of Imaging* 10.6 (2024), p. 149.
- [9] Huang, Jie et al. “Attention-based 3D-CNNs for large-vocabulary sign language recognition”. In: *IEEE Transactions on Circuits and Systems for Video Technology* 29.9 (2018), pp. 2822–2832.
- [10] Isaac, Joseph HR, Manivannan, Muniyandi, and Ravindran, Balaraman. “Single Shot Corrective CNN for Anatomically Correct 3D Hand Pose Estimation”. In: *Frontiers in Artificial Intelligence* 5 (2022), p. 759255.
- [11] Jin, Peng et al. *MoH: Multi-Head Attention as Mixture-of-Head Attention*. 2025. arXiv: 2410.11842 [cs.CV]. URL: <https://arxiv.org/abs/2410.11842>.
- [12] Konstantinidis, Dimitrios, Dimitropoulos, Kosmas, and Daras, Petros. “A deep learning approach for analyzing video and skeletal features in sign language recognition”. In: *2018 IEEE international conference on imaging systems and techniques (IST)*. IEEE. 2018, pp. 1–6.
- [13] Konstantinidis, Dimitrios, Dimitropoulos, Kosmas, and Daras, Petros. “Sign language recognition based on hand and body skeletal data”. In: *2018-3DTV-conference: The true vision-capture, transmission and display of 3D video (3DTV-Con)*. IEEE. 2018, pp. 1–4.

- [14] LI, DONGXU et al. “Word-level Deep Sign Language Recognition from Video: A New Large-scale Dataset and Methods Comparison”. In: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. Mar. 2020.
- [15] Li, Dongxu et al. “Word-level deep sign language recognition from video: A new large-scale dataset and methods comparison”. In: *Proceedings of the IEEE/CVF winter conference on applications of computer vision*. 2020, pp. 1459–1469.
- [16] Li, Zecheng et al. *Uni-Sign: Toward Unified Sign Language Understanding at Scale*. 2025. arXiv: 2501.15187 [cs.CV]. URL: <https://arxiv.org/abs/2501.15187>.
- [17] O’shea, Keiron and Nash, Ryan. “An introduction to convolutional neural networks”. In: *arXiv preprint arXiv:1511.08458* (2015).
- [18] Pu, Muxin, Lim, Mei Kuan, and Chong, Chun Yong. *Siformer: Feature-isolated Transformer for Efficient Skeleton-based Sign Language Recognition*. 2025. arXiv: 2503.20436 [cs.CV]. URL: <https://arxiv.org/abs/2503.20436>.
- [19] Ronchetti, Franco et al. *LSA64: An Argentinian Sign Language Dataset*. 2023. arXiv: 2310.17429 [cs.CV]. URL: <https://arxiv.org/abs/2310.17429>.
- [20] Ross, Lawrence M et al. *Thieme Atlas of Anatomy: General Anatomy and Musculoskeletal System*. Georg Thieme Verlag, 2006.
- [21] Sarkar, Ushnish et al. *Enhancing ASL Recognition with GCNs and Successive Residual Connections*. 2024. arXiv: 2408.09567 [cs.CV]. URL: <https://arxiv.org/abs/2408.09567>.
- [22] Schmidt, Robin M. *Recurrent Neural Networks (RNNs): A gentle Introduction and Overview*. 2019. arXiv: 1912.05911 [cs.LG]. URL: <https://arxiv.org/abs/1912.05911>.
- [23] Shah, Jai Amrish et al. “Deepsign: A deep-learning architecture for sign language”. PhD thesis. 2018.
- [24] Simonyan, Karen and Zisserman, Andrew. *Two-Stream Convolutional Networks for Action Recognition in Videos*. 2014. arXiv: 1406.2199 [cs.CV]. URL: <https://arxiv.org/abs/1406.2199>.
- [25] Song, Sijie et al. “An end-to-end spatio-temporal attention model for human action recognition from skeleton data”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 31. 1. 2017.
- [26] Starner, Thad E. “Visual Recognition of American Sign Language Using Hidden Markov Models”. Master’s thesis, advisor: Alex Pentland. MA thesis. Cambridge, MA: Massachusetts Institute of Technology, Media Laboratory, 1995.
- [27] Wang, Xiong et al. *Efficient Conformer with Prob-Sparse Attention Mechanism for End-to-End Speech Recognition*. 2021. arXiv: 2106.09236 [cs.SD]. URL: <https://arxiv.org/abs/2106.09236>.
- [28] Yan, Sijie, Xiong, Yuanjun, and Lin, Dahua. *Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition*. 2018. arXiv: 1801.07455 [cs.CV]. URL: <https://arxiv.org/abs/1801.07455>.

- [29] Zhang, Xinyu and Li, Xiaoqiang. “Dynamic gesture recognition based on MEMP network”. In: *Future Internet* 11.4 (2019), p. 91.
- [30] Zhou, Wangchunshu et al. “Bert loses patience: Fast and robust inference with early exit”. In: *Advances in Neural Information Processing Systems* 33 (2020), pp. 18330–18341.